

Extensiones de Machine Learning.

Práctica 1: Bandido de k-brazos

José María Hernández Nieto
Juan de Dios Rodríguez Garrido
Javier García Serrano

{josemaria.hernandezn, juandios.rodriguezg, j.garciaserrano1}@um.es

9 de marzo de 2025

Resumen

En este documento, se estudia el rendimiento de distintos algoritmos diseñados para abordar el problema del bandido de k brazos, incluyendo ε -greedy, UCB-1, UCB-2, Softmax y gradiente de preferencias. Estos métodos presentan diferentes estrategias para explorar o explotar el espacio de soluciones, desde enfoques sencillos basados en exploración aleatoria hasta modelos más sofisticados que emplean índices de confianza o aprendizaje basado en gradiente. Además, se analiza cómo el desempeño de estos algoritmos varía en función de la distribución de recompensas de los brazos del bandido, considerando tres tipos de distribuciones: normal, Bernoulli y binomial.

La parte experimental de esta práctica puede encontrarse en el siguiente repositorio: https://github.com/JoseHernandez11/k_brazos_JMHJDRJG

1. Introducción

El problema del bandido multibrazo resulta fundamental en el campo del aprendizaje por refuerzo. Se trata de un escenario en el que un agente debe elegir repetidamente entre k opciones (o brazos), cada uno de los cuales otorga una recompensa que sigue una distribución de probabilidad desconocida. El objetivo del agente es maximizar la recompensa acumulada, es decir, elegir siempre aquellos brazos que le proporcionen mayores recompensas con objeto de, al final de las iteraciones, haber obtenido la mejor recompensa global.

El problema del bandido multibrazo es un modelo fundamental en la toma de decisiones secuenciales bajo incertidumbre, con aplicaciones en diversos dominios como la salud (ensayos clínicos y dosificación de medicamentos), finanzas (optimización de la cartera de valores), marketing y ventas digitales (selección de anuncios maximizando tasas de conversión) e incluso dentro de inteligencia artificial (entrenamiento de chat bots).

Uno de los aspectos claves a considerar al tratar de encontrar una solución del problema del bandido multibrazo es el dilema entre la exploración y explotación. El agente tendrá en cada iteración dos opciones: explorar (buscar nuevas mejores soluciones) o explotar (optar por el brazo que se considera mejor en ese momento). En este contexto, surgen numerosos algoritmos para resolver el problema del bandido multibrazo que establecen una serie de criterios para saber cuándo se explora

y cuándo se explota, además de definir diferentes estrategias de exploración.

En este contexto, dentro del informe compararemos el rendimiento de diferentes algoritmos para resolver el problema de bandido de k brazos. Concretamente: ε -greedy (algoritmo sencillo en el que se explora con una probabilidad ε eligiendo al azar entre los brazos considerados subóptimos y se explota el brazo óptimo en el resto de ocasiones), UCB-1 y UCB-2 (algoritmos más sofisticados basados en índices de confianza que priorizan explorar aquellos brazos cuya distribución de recompensa es más desconocida) y Softmax y gradiente de preferencias (basados en el gradiente).

El rendimiento de los algoritmos no solo depende de la estrategia que siguen a la hora de determinar cuándo explorar o explotar, ni tampoco de su forma de explotar. Un aspecto importante a tener en cuenta al medir el rendimiento de los algoritmos es que su desempeño también depende de la distribución de probabilidad que sigan las recompensas de los brazos del bandido. Por ello, en esta práctica consideraremos bandidos cuyos brazos presentan distribuciones de probabilidad de recompensa de tipo normal, Bernoulli y binomial.

El presente documento tiene como objetivo documentar el estudio y la experimentación con distintos algoritmos (ε -greedy, UCB-1, UCB-2, Softmax, gradiente de preferencias) para la resolución del problema del bandido de k -brazos cuando las recompensas de dichos brazos siguen distintas distribuciones de probabilidad (normal, Bernoulli, binomial). El contenido del informe se sigue la siguiente estructura: en la *Sección 2* se definirá formalmente el problema abordado, sus principales aplicaciones y los algoritmos que se van a utilizar para su resolución; en la *Sección 3*, se explicarán en detalle los algoritmos utilizados y sus hiperparámetros, en la *Sección 4* se explicarán los experimentos desarrollados, mostrandos las gráficas obtenidas y comentando los resultados. Por último, cerraremos el informe con la *Sección 5* donde incluiremos las principales conclusiones que hemos obtenido en nuestro estudio.

2. Desarrollo

El problema del bandido de K brazos es un problema fundamentalmente y de gran popularidad dentro del campo aprendizaje por refuerzo, siendo uno de los primeros que se estudia al iniciarse en dicho campo debido a su gran cantidad de apli-

caciones y a que sienta las bases de conocimiento para poder abordar problemas más complejos. Se trata de un escenario en el que un agente debe elegir repetidamente entre K opciones (brazos), cada una de las cuales otorga recompensas según una distribución de probabilidad desconocida.

Una analogía ampliamente utilizada para describir este problema es la de un casino con K máquinas tragaperras (o "bandidos"), donde cada máquina tiene una distribución de recompensas (dinero que reparte cuando se juega dicha máquina) diferente y desconocida. El jugador (agente) puede jugar en una máquina (accionar un brazo) en cada turno o iteración, recibiendo una recompensa que sigue una distribución específica para esa máquina. Su objetivo es descubrir, a través de la experiencia, cuál de las máquinas tiene una distrución de pago más ventajosa y así maximizar la recompensa total obtenida a lo largo de T iteraciones. Matemáticamente, se trata de maximizar el valor esperado de la suma de las recompensas obtenidas a lo largo de todas las iteraciones:

$$\max \mathbb{E} \left[\sum_{t=1}^T R_t \right] \quad (1)$$

El ejemplo de las tragaperras sirve también para introducir uno de los aspectos más importantes dentro del campo del aprendizaje por refuerzo: el dilema de la exploración frente a la explotación. El jugador (agente) tendrá en cada iteración dos opciones: explorar, es decir, probar a jugar a una tragaperras distinta de la que cree que da los mejores premios con objeto de poder descubrir que existe otra mejor que la ya que conocía o, explotar, entendiendo esto como jugar a la máquina que considera más ventajosa para maximizar así la cantidad de dinero ganado.

Un concepto fundamental en este contexto es el regret acumulado, que mide la diferencia entre la recompensa obtenida y la que se habría obtenido seleccionando siempre el mejor brazo:

$$R(T) = T\mu^* - \mathbb{E} \left[\sum_{t=1}^T R_t \right] \quad (2)$$

donde $\mu^* = \max_i \mu_i$ representa la recompensa esperada óptima. Si volvemos a la analogía de las máquinas tragaperras, el regret se definiría como la diferencia entre el dinero total ganado si siempre hubiésemos elegido la máquina que tiene una distribución de premios más ventajosa y el total de dinero que hemos ganado. Reducir el regret es clave para diseñar estrategias eficientes que combinen la exploración y la explotación de la manera más óptima posible.

El objetivo de cualquier algoritmo que trate de resolver el problema del bandido multibrazo de manera óptima es minimizar el regret acumulado. Existe una cota inferior para el regret acumulado, que no puede decrecer más rápido que $O(\ln T)$ [1]. Esto se interpreta como que siempre es necesaria una fase de exploración para poder conocer lo suficiente las funciones de recompensa de los diferentes brazos y hacer la explotación de acuerdo a dicho conocimiento. Los algoritmos más sencillos, como ε -greedy, llegan a presentar regrets acumulados lineales para valores de ε muy cercanos a 0, mientras

que otros más elaborados, como UCB, consiguen esta caída logarítmica.

Otra métrica que resulta especialmente útil a la hora de evaluar el desempeño en los bandidos multibrazos es el porcentaje de selecciones óptimas: la fracción de veces (o probabilidad) con la que el algoritmo escoge el brazo óptimo. A medida que un buen algoritmo aprende, esperaremos que esta probabilidad tienda a 1 (o el porcentaje correspondiente tienda al 100 %) conforme t aumenta, indicando que eventualmente casi siempre se elige la mejor opción. En los experimentos realizados como parte de esta práctica, observaremos cómo evoluciona esta métrica con las iteraciones, comparando así la rapidez con la que cada método converge hacia la elección óptima.

2.1. Aplicaciones del bandido multibrazo

El problema del bandido multi-brazo es un modelo ampliamente utilizado en la toma de decisiones secuenciales bajo incertidumbre, teniendo numerosas aplicaciones en sectores muy diversos como pueden ser la salud, las finanzas, el comercio electrónico, la publicidad digital y la inteligencia artificial [2]. Algunos ejemplos de aplicaciones dentro de los campos citados serían los siguientes:

- En el ámbito de la salud, los bandidos multibrazo son usados principalmente en ensayos clínicos. De esta manera, se trata de optimizar el número de pacientes que reciben las terapias más prometedoras para tratar una enfermedad, mientras que aquellos tratamientos menos eficaces se les suministran a un menor número de pacientes. De esta manera, la mayor parte de pacientes recibe el que se considera el mejor tratamiento pero siempre se experimenta con otras opciones por si se descubriera que una de ellas otorga mejores resultados.
- En la economía y toma de decisiones financieras, los bandidos ayudan a los gestores de patrimonio a explorar nuevas oportunidades de inversión y explotar aquellas inversiones que consideran más rentables, consiguiendo así maximizar los beneficios y ser resilientes ante la volatilidad de los diferentes mercados.
- En publicidad y comercio electrónico, se puede optimizar qué tipo de anuncios se muestran a los consumidores usando una estrategia basada en bandidos: cuando no se tenga información previa sobre el usuario se mostrarán todo tipo de anuncios (exploración) pero a medida que se recoja como el usuario interacciona con ellos y cuáles han sido capaces de provocar alguna reacción en el mismo (ya sea hacer click en el anuncio o conseguir una venta del producto), se pasará a la fase de explotación: mostrar al usuario sólo aquellos anuncios que puedan interesarle más con objeto de aumentar las ventas.
- Por último, y una aplicación relativamente novedosa y relacionada con el campo de la inteligencia artificial, es el uso de los bandidos para el entrenamiento de chatbots. Así, asignando a cada respuesta una cierta recompensa en función de como de útil la considere el usuario final se pueden encontrar qué respuestas son las que les resultan interesantes a la mayoría de usuarios y mejorar el desempeño de asistentes virtuales.

2.2. Métodos Existentes para la resolución del bandido multibrazo

El conflicto entre exploración y explotación que hemos definido anteriormente resulta clave a la hora de desarrollar algoritmos para encontrar una solución lo más óptima al problema. No solo resulta fundamental para encontrar una solución óptima al problema saber cuándo hay que explorar o explotar, sino también definir una estrategia de exploración óptima que permita detectar, en pocas iteraciones, el brazo óptimo, reduciendo así el número de exploraciones y permitiendo aprovechar al máximo la explotación del mejor brazo.

A lo largo de los años, se han desarrollado diversos enfoques para resolver el problema del bandido de K brazos:

Estrategia aleatorias: Se trata de la solución más sencilla, simplemente selecciona un brazo aleatorio en cada iteración. Se trata de una solución totalmente exploratoria, la cual resulta trivial pero subóptima.

Un método más sofisticado, que ya es capaz de combinar exploración y explotación, es ε -greedy. De esta forma, existirá una probabilidad ε de que el algoritmo explore y la probabilidad complementaria de que explore la solución óptima hasta el momento. Se trata de la aproximación más sencilla que balancea exploración y explotación.

Métodos basados en índices de confianza: Algoritmos como UCB1 [3] utilizan bonificaciones por incertidumbre para guiar la exploración. De esta manera, se centran en explorar aquellos brazos de cuya distribución de recompensas tienen una menor información, consiguiendo así detectar rápidamente el brazo óptimo y alcanzando un regret logarítmico. Existen otras variantes como UCB2 refinan estos métodos para mejorar su eficiencia en distintas configuraciones.

Métodos de gradiente: Softmax y el gradiente de preferencias ajustan probabilidades de selección en función de un procedimiento de ascenso de gradiente [4]. Son flexibles pero dependen de la calibración de hiperparámetros (τ en Softmax y α en el gradiente de preferencias).

Otros métodos: Además de las estrategias mencionadas, existen enfoques alternativos que han demostrado ser eficaces en distintos escenarios. Uno de los más relevantes es el *Muestreo de Thompson*, un método bayesiano que selecciona brazos de acuerdo con una distribución de probabilidad sobre sus recompensas esperadas. A diferencia de los métodos basados en índices de confianza, el muestreo de Thompson incorpora información previa y actualiza sus creencias a medida que se recopilan datos, lo que lo hace especialmente efectivo en entornos dinámicos o con cambios en las distribuciones de recompensa. Otro enfoque importante es el de los bandidos adversariales, diseñados para entornos en los que las recompensas no son estacionarias y pueden depender de decisiones externas o estrategias de un adversario.

En este estudio, nos enfocamos en los algoritmos ε -greedy, UCB1/UCB2, Softmax y gradiente de preferencias evaluándolos en un entorno estacionario, dejando fuera métodos bayesianos, bandidos adversariales y otros métodos.

2.3. Distribuciones de Recompensa Consideradas

El objetivo de esta práctica es evaluar qué algoritmos de resolución del problema del bandido son más óptimos. No obstante, el desempeño de dichos algoritmos no depende únicamente de la estrategia que siguen los mismos, sino que también ha de tenerse en cuenta la distribución de probabilidad que siguen las recompensas de los brazos de los bandidos. Un algoritmo puede obtener unos resultados muy buenos cuando los brazos del bandido que resuelve siguen una distribución de probabilidad determinada, pero no generalizar bien a otro tipo de distribuciones y obtener resultados mediocres. De esta manera, el estudio llevado a cabo como parte de esta práctica considera diferentes distribuciones de probabilidad y evalúa el desempeño de los algoritmos de resolución del bandido previamente explicados en diferentes escenarios. Las distribuciones de probabilidad consideradas para los brazos son tres de las más comunes en estadística:

Distribución Normal $N(\mu, \sigma^2)$: Se emplea para modelar recompensas continuas en entornos donde las observaciones pueden tomar cualquier valor real dentro de un rango. En este caso, la media μ se selecciona aleatoriamente en el intervalo $[1, 10]$, mientras que la desviación estándar se fija en $\sigma = 1$. Esta configuración es útil en situaciones donde las recompensas varían gradualmente en torno a un valor medio, con fluctuaciones naturales que reflejan la incertidumbre. Un ejemplo de aplicación de este tipo de distribución es la predicción del rendimiento de una campaña publicitaria, donde la efectividad de un anuncio no es determinista, sino que presenta variaciones en función del contexto y la audiencia.

Distribución Bernoulli: Se utiliza en contextos donde la recompensa es binaria, es decir, el resultado de cada acción es éxito ($R = 1$) con probabilidad p o fracaso ($R = 0$) con probabilidad $1 - p$. Esta distribución es especialmente relevante en problemas donde el resultado de cada decisión es binario, como en pruebas A/B. Un ejemplo claro es evaluar si un usuario hace clic en un anuncio o no, donde cada interacción puede modelarse como un experimento Bernoulli, permitiendo a los algoritmos de bandido multi-brazo optimizar qué contenido mostrar.

Distribución Binomial $B(n, p)$: Se obtiene al repetir n veces un experimento Bernoulli con probabilidad de éxito p , generando valores entre 0 y n . En este estudio, se ha seleccionado $n = 5$ y p muestreado en el intervalo $(0, 1, 0, 9)$ para evitar los casos extremos: cuando $n = 1$, donde la distribución sería una Bernoulli, y cuando n es muy grande, donde la distribución tiende a una normal. Esta distribución resulta útil en situaciones donde se requiere modelar la cantidad de éxitos en un número fijo de intentos. Un posible caso de aplicación es evaluar el número de veces que un usuario interactúa con un producto en una tienda en línea tras haber visto un anuncio.

En todos los casos, asumimos distribuciones estacionarias, es decir, donde los parámetros de recompensa no varían con el tiempo.

3. Algoritmos

En esta sección nos vamos a explicar los algoritmos ε -greedy, UCB-1, UCB-2, Softmax y gradiente de preferencias para la resolución del problema del bandido multibrazo, los cuales probaremos su rendimiento en las tres distribuciones de probabilidad de la recompensa de los brazos que hemos explicado en la sección anterior (normal, Bernoulli, binomial). En cuanto a la estructura de esta sección, al haber estudiado ya estos algoritmos en clase y sus respectivos pseudocódigos, nos centraremos en explicar la lógica de como funcionan, sus funciones de actualización e hiperparámetros (ε en ε -greedy, α en UCB-2, τ en Softmax y α en el gradiente de preferencias).

3.1. Método ε -greedy

El enfoque ε -greedy supone una estrategia sencilla pero en muchos casos eficaz para afrontar el dilema exploración/explotación. Su funcionamiento es muy sencillo: para cada paso, con probabilidad $1 - \varepsilon$ el agente explota seleccionando la máquina (brazo) que hasta el momento tiene la mayor recompensa media estimada; y con probabilidad ε realiza una exploración seleccionando un brazo al azar de manera uniforme entre el resto de brazos. De este manera, ε controla la tasa de exploración: si $\varepsilon = 0$ el comportamiento es puramente explotatorio (siempre elegir el brazo estimado como mejor), mientras que si $\varepsilon = 1$ las acciones son completamente exploratorias.

En cuanto a su funcionamiento, el método ε -greedy estima la recompensa de cada brazo como la media de las recompensas obtenidas hasta el momento para ese brazo.

3.2. Métodos UCB (UCB-1 y UCB-2)

Los algoritmos de *Upper Confidence Bound* (UCB) abordan el dilema exploración-explotación desde una perspectiva más optimista: en cada paso, se selecciona el brazo con el mayor potencial considerando tanto su rendimiento medio como la incertidumbre en dicha estimación. De esta manera, a cada brazo j se le asocia un índice I_j que es la suma de dos términos: la recompensa media estimada $\bar{X}_j$ (hasta el momento) y un término de incertidumbre que aumenta cuando el brazo j ha sido poco explorado y decrece a medida que j se juega con frecuencia. El algoritmo elige el brazo con el índice I_j más alto, siguiendo una estrategia de "optimismo ante la incertidumbre", es decir, asume que los brazos no explorados pueden dar muy buenos resultados de modo que vale la pena explorarlos.

En el caso de **UCB-1**, se tiene matemáticamente que para cada brazo a :

$$UCB1(a) = Q(a) + c \cdot \sqrt{\frac{\ln t}{N(a)}} \quad (3)$$

Independientemente del valor de c (que define el grado de exploración y en este experimento se fijará $c = 1$ como en la formulación original), al aumentar el número de veces que hemos jugado un brazo $N(a)$, el factor exploratorio va decreciendo y cada vez tiene mayor peso la recompensa promedio obtenida en dicho brazo $Q(a)$. De esta manera, en los brazos

jugados pocas veces el término exploratorio crecerá mucho lo que resultará en que los mismos se exploten. Cuando todos hayan sido explorados varias veces, se tenderá a que el término explotatorio del mejor brazo domine aunque se sigue conservando cierta posibilidad de escoger a otros debido al término $\sqrt{\frac{\ln t}{N(a)}}$ que hace el UCB1 se vaya reduciendo (al caer más rápido N que $\ln t$ cuando para todas las t se elige el brazo óptimo $\lim_{x \rightarrow 0} \frac{\ln(x)}{x} = 0$, estando el término exploratorio cada vez más presente en los otros brazos).

Por otra parte, **UCB-2** es una variante mejorada del algoritmo UCB-1. En esta versión del algoritmo se introduce el concepto de época, de forma que, en lugar de explorar una única vez los brazos y volver a evaluar la función, se explora el brazo varias veces en lo que se conoce como época. De esta manera, se consiguen evitar cambios de brazo constantes. Matemáticamente:

$$UCB2(a) = Q(a) + r \frac{(1 + \alpha) \cdot \ln(\frac{e \cdot t}{\tau(k_a)})}{2\tau(k_a)} \quad (4)$$

El parámetro α en UCB-2 controla el tamaño relativo de las épocas: valores de α cercanos a 0 hacen que las épocas sean más largas haciendo exploración más agresiva de cada brazo cuando le toca su turno, mientras que valores α mayores acortan las épocas. Por lo general, UCB-2 es poco sensible a la elección exacta de α siempre que sea "relativamente pequeño" [3].

3.3. Métodos Softmax y Gradiente de Preferencias

Se trata de otra familia de exploración estocástica: asigna una probabilidad a cada brazo en función de lo bien que lo ha hecho hasta ahora y luego selecciona aleatoriamente un brazo de acuerdo a esas probabilidades en cada jugada. La diferencia respecto al resto de métodos estudiados es que siempre se toma una decisión aleatoria basándose en los valores estimados de las recompensas de los brazos (en ε -greedy es totalmente aleatoria entre los brazos no considerados como óptimos y en UCB tiene en cuenta valores medios e incertidumbres).

El método **Softmax** asigna probabilidades $\pi_t(a)$ a cada brazo a usando una distribución de Boltzmann (softmax) sobre sus valores estimados $Q_t(a)$. En su forma clásica, la probabilidad de seleccionar el brazo a en el tiempo t se define como:

$$\pi_t(a) = \frac{\exp(Q_t(a)/\tau)}{\sum_{b=1}^K \exp(Q_t(b)/\tau)} \quad (5)$$

donde $\tau > 0$ es el hiperparámetro de temperatura. Este parámetro controla el equilibrio entre exploración y explotación:

- ▶ Valores altos de τ ($\tau \gg 1$) generan una distribución casi uniforme, favoreciendo la exploración ($\exp(Q_t(a)/\tau) \approx 1$ para todos los brazos cuando τ es grande).
- ▶ Valores bajos de τ ($\tau \approx 0$) hacen que la distribución se concentre en el brazo con mayor recompensa estimada, tendiendo a un comportamiento codicioso y altamente

explotatorio a medida que $\tau \rightarrow 0$.

De esta manera, Softmax permite una exploración más estructurada que la selección completamente aleatoria (ε -greedy), ajustando suavemente la probabilidad de elegir cada brazo en función de su estimación de recompensa.

El método de **gradiente de preferencias** adopta un enfoque diferente: en lugar de estimar valores Q_j , mantiene para cada brazo j un parámetro H_j que representa la *preferencia* aprendida hacia ese brazo. Estas preferencias se actualizan en cada paso mediante un algoritmo de gradiente ascendente que busca maximizar la recompensa esperada. El resultado a largo plazo es que las preferencias H_j tienden a ser mayores para los brazos con mayores recompensas promedio, llevando a que la preferencia se aproxime a 1 para el brazo óptimo (y a 0 para los demás) si α es suficientemente pequeño o decreciente para asegurar convergencia. En la práctica, se suele elegir una α fija pequeña (por ejemplo 0.1) para problemas estacionarios; valores de α muy grandes pueden causar inestabilidad, mientras que valores muy pequeños conllevan convergencia muy lenta.

4. Experimentos

Esta sección la vamos a estructurar en cuatro sub-secciones: estudio de desempeño del algoritmo ε -greedy, estudio de desempeño de la familia de algoritmos UCB, estudio de algoritmos basados en el gradiente, estudio final comparando todas las familias. Se hará una búsqueda con distintos valores de hiperparámetros dentro de cada familia para las distribuciones normal, Bernoulli y binomial. Para cada algoritmo y combinación de hiperparámetros, se generará un bandido de 10 brazos y se ejecutarán 1000 iteraciones. Este proceso se repetirá 500 veces para asegurarnos de obtener resultados estadísticamente significativos mediante el promedio de los resultados individuales. Al final de cada estudio se destacará cual es la mejor combinación de hiperparámetros de cada algoritmo para las distintas distribuciones de probabilidad de los brazos.

El código base para la realización de estos experimentos es el proporcionado por el profesor [5].


4.1. Estudio de la familia de algoritmos ε -greedy.

Para ε -greedy se probarán con diferentes combinaciones de valores, $\varepsilon = [0$ (azul), 0.01 (naranja), 0.05 (verde), 0.10 (rojo), 0.50 (morado)], yendo desde de valores puramente explotatorios $\varepsilon = 0$ a muy explotarios $\varepsilon = 0.50$.


4.1.1. ε -greedy para distribución normal.

Observando las gráficas de la Figura 1, podemos apreciar que en la gráfica que muestra la recompensa acumulada promedio que los mejores resultados se obtienen en las estrategias que son moderadamente exploratorias $\varepsilon = 0.05, 0.10$ (verde y rojo respectivamente). La opción puramente exploratoria ($\varepsilon = 0$ azul) queda atrapada en la primera elección (gráfica c) y no es capaz de hacer ninguna selección óptima. También queda reflejado que opciones muy exploratorias ($\varepsilon=0.5$) no convergen a una recompensa acumulada máxima, al haber un 50 % de


elecciones aleatorias (gráfica e). Finalmente, el plot de regret acumulado muestra una evolución lineal en el caso de $\varepsilon = 0$, y una caída mucho más rápida en el resto de configuraciones. El mejor valor para ε en términos de convergencia es $\varepsilon = 0.1$, como puede apreciarse en las gráficas a,b y f.



(a) Evolución de la recompensa(b) Evolución del porcentaje de selecciones óptimas



(c) Estadísticas de brazo $\varepsilon = 0$ (d) Estadísticas de brazo $\varepsilon = 0.1$




(e) Estadísticas de brazo $\varepsilon = 0.5$ (f) Evolución del rechazo acumulado

Figura 1: Resultados del estudio de ε -greedy para la distribución normal.

4.1.2. ε -greedy para distribución de Bernoulli.

Observando las gráficas de la Figura 2, podemos apreciar como las gráficas presentan un ruido mucho más significativo, al presentar la distribución de Bernoulli recompensas binarias 0 o 1. La opción puramente exploratoria ($\varepsilon = 0$ azul) sigue quedando atrapada y los mejores resultados se obtienen en las estrategias que son moderadamente exploratorias $\varepsilon = 0.05, 0.10$ (verde y rojo respectivamente). Finalmente, el plot de regret acumulado muestra una evolución lineal en el caso de $\varepsilon = 0, 0.01, 0.50$, y una caída mucho más rápida en las configuraciones moderadamente exploratorias. El mejor valor para ε en términos de convergencia es $\varepsilon = 0.1$.




(a) Evolución del porcentaje de selecciones óptimas (b) Evolución del rechazo acumulado

Figura 2: Resultados del estudio de ε -greedy para la distribución de Bernoulli.

4.1.3. ε -greedy para distribución binomial.

Observando las gráficas de la Figura 3, observamos una tendencia similar a la que ya hemos visto para el resto de distribuciones de probabilidad: las estrategias moderadamente exploratorias $\varepsilon = 0,05, 0,10$ (verde y rojo respectivamente) son las que mejores resultados consiguen, teniendo una convergencia rápida. Las gráficas siguen presentando un ruido significativo. El mejor valor para ε en términos de convergencia es $\varepsilon = 0,1$, resaltando especialmente frente a $\varepsilon = 0,05$ para esta distribución.



(a) Evolución del porcentaje de selecciones óptimas (b) Evolución del rechazo acumulado

Figura 3: Resultados del estudio de ε -greedy para la distribución binomial.

4.1.4. Análisis resultados ε -greedy.

En general, los diferentes hiperparámetros se comportan de manera bastante similar para las distribuciones consideradas. La configuración puramente exploratoria $\varepsilon = 0$, es la que siempre obtiene peores resultados, quedando atascada en la solución elegida inicialmente sin opción a progresar. La opción altamente exploratoria $\varepsilon = 0,5$ se ve penalizada al seguir explorando pese a haber encontrado la solución óptima. Son las opciones moderadamente exploratorias las que mejores resultados obtienen, destacando $\varepsilon = 0,1$ que consigue la mejor convergencia para todas las distribuciones y que será la que utilizaremos para el estudio final.


4.2. Estudio de la familia de algoritmos UCB.

Para UCB-1 se fijará $c = 1$ (azul), como en la formulación original. Para UCB-2, elegimos tres valores de $\alpha = [0.01$ (naranja), 0.1 (verde), 0.9 (rojo)], aunque ya hemos comentado en la sección anterior que valores pequeños suelen obtener resultados satisfactorios.


4.2.1. Familia UCB para distribución normal.

En la Figura 4 podemos apreciar distintas representaciones de los resultados obtenidos. En la gráfica de evolución de recompensa acumulada, podemos apreciar como todas las configuraciones de UCB consiguen una convergencia rápida hacia la recompensa máxima. En la gráfica del porcentaje de selecciones óptimas apreciamos que las mejores configuraciones son UCB-1 y UCB-2 con $\alpha = 0,1$, lo que podemos confirmar también en la gráfica del rechazo acumulado. También cabe comentar las oscilaciones que vemos en todos los métodos UCB al principio de la gráfica de evolución de la recompensa acumulada respecto a las iteraciones. Si miramos las ecuaciones 3 y 4, podemos averiguar que estas oscilaciones se corresponden con la primera iteración en la que se explora el brazo óptimo, el valor de las funciones UCB aumenta mucho y se explota durante unas cuantas épocas hasta que el término


exploratorio aumenta, al aumentar t . Más adelante, cuando todos los brazos han sido explorados todos los brazos, vuelve a converger ya de forma estable.



(a) Evolución de la recompensa acumulada



(b) Evolución del porcentaje de selecciones óptimas




(c) Evolución del rechazo acumulado

Figura 4: Resultados del estudio de la familia UCB para la distribución normal.

4.2.2. Familia UCB para distribución de Bernoulli.

Observando las gráficas de la Figura 5, podemos apreciar como las gráficas presentan un ruido mucho más significativo, al presentar la distribución de Bernoulli recompensas binarias 0 o 1. En este caso, los mejores resultados los obtiene UCB-2 con $\alpha = 0,1$, superando esta vez UCB-2 ($\alpha=0.9$) a UCB-1, aunque esta segunda opción de UCB-2 presenta fuertes oscilaciones en la gráfica de porcentaje de selecciones óptimas. De nuevo, un carácter exploratorio muy bajo $\alpha = 0,01$ para UCB-2 es la opción que arroja los peores resultados, debido a que tiende a una carácter explotatorio puro.




(a) Evolución del porcentaje de selecciones óptimas (b) Evolución del rechazo acumulado

Figura 5: Resultados del estudio de familia UCB para la distribución de Bernoulli.

4.2.3. Familia UCB para distribución binomial.

Observando las gráficas de la Figura 6, vemos ya una diferencia clara entre el rendimiento de UCB-1 y UCB-2, obteniendo unos resultados bastante peores en el caso de UCB-1 que en las mejores combinaciones de UCB-2, especialmente en las gráficas de rechazo acumulado, donde se equipara a la configuración cuasi-exploratoria de UCB-2 ($\alpha = 0,01$). La configuración moderadamente exploratoria de UCB-2 ($\alpha = 0,1$) sigue obteniendo los mejores resultados en ambas gráficas.



(a) Evolución del porcentaje de selecciones óptimas (b) Evolución del rechazo acumulado

Figura 6: Resultados del estudio de UCB para la distribución binomial.

4.2.4. Análisis resultados familia UCB.

En cuanto a los resultados globales de la familia UCB, UCB-2 con $\alpha = 0,1$ es el algoritmo más consistente en todas las distribuciones y será el que cojamos como ganador representante de los UCB para hacer la comparación final. En cuanto al UCB-1, obtiene buenos resultados en las distribuciones de Bernoulli y normal, pero empeora notablemente en la binomial. La configuración altamente exploratoria de UCB-2 $\alpha = 0,9$ por lo general obtiene resultados decentes aunque por debajo de una versión con exploración más moderada. La configuración casi plenamente explotatoria de UCB-2 ($\alpha = 0,01$) es la que peores resultados obtiene para todas las distribuciones, debido a que explora muy pocas veces y no llega a conocer bien las distribuciones de recompensa de los diversos brazos.


4.3. Estudio de la familia de algoritmos basados en el gradiente.

Para Softmax experimentaremos con tres valores para la temperatura $\tau = [0,1, 1, 10]$ (azul, naranja y verde respectivamente), mientras que para el gradiente de preferencias nos limitaremos a probar $\alpha = 0,1$ (rojo) como hemos explicado en la sección anterior.


4.3.1. Algoritmos basados en el gradiente para distribución normal.

En la Figura 7, podemos observar como se comportan los distintos algoritmos basados en gradientes con una distribución normal de las recompensas de los brazos. Vemos que el algoritmo Softmax, en cualquiera de sus configuraciones obtiene unos resultados considerablemente peores a los del gradiente de preferencias. Los mejores resultados para este algoritmo se obtienen cuando se opta por un $\tau = 1$, considerado la configuración estándar, consiguiendo las configuraciones muy exploratorias (τ grande) o muy explotatorias (τ pequeño) un desempeño muy malo: porcentaje de selecciones óptimas 0,1


(las veces que de primeras elige el brazo bueno) y curvas de rechazo acumulado que crecen de forma lineal con t .



(a) Evolución de la recompensa acumulada



(b) Evolución del porcentaje de selecciones óptimas




(c) Evolución del rechazo acumulado

Figura 7: Resultados del estudio de algoritmos basados en el gradiente para distribución normal.

4.3.2. Algoritmos basados en el gradiente para distribución de Bernoulli.

Observando las gráficas de la Figura 8, vemos que el gradiente de preferencia sigue siendo el ganador en el porcentaje de selecciones óptimas, aunque sorprende el gran desempeño de Softmax para $\tau = 0,1$, consiguiendo superar incluso al gradiente de preferencias en el caso del regret acumulado, mientras que los otros valores de τ obtienen resultados paupérrimos. Este fenómeno puede deberse a la propia distribución de Bernoulli, al ser las recompensas binarias (0 o 1), los valores de la recompensa esperada de cada brazo se estabilizan rápido y una estrategia de explotación fuerte (bajo τ) converge rápido hacia el mejor brazo.




(a) Evolución del porcentaje de selecciones óptimas (b) Evolución del rechazo acumulado

Figura 8: Resultados de los algoritmos basados en el gradiente para la distribución de Bernoulli.

4.3.3. Algoritmos basados en el gradiente para distribución binomial.

Para el caso de la distribución binomial en los algoritmos basados en gradientes, las gráficas de la Figura 9 nos muestran que vuelven a darse curvas muy similares a las que ya hemos comentado para la distribución normal.



(a) Evolución del porcentaje de selecciones óptimas (b) Evolución del rechazo acumulado

Figura 9: Resultados del estudio de algoritmos basados en el gradiente para la distribución binomial.

4.3.4. Análisis de resultados de algoritmos basados en el gradiente.

En cuanto a los resultados globales de la familia de algoritmos basados en el gradiente, podemos detectar que el gradiente de preferencias es la configuración más consistente y que consigue obtener los mejores resultados en todas las distribuciones. En cuanto a la función softmax, un parámetro de temperatura estándar $\tau = 1$, resulta más adecuado para las distribuciones normal y binomial, mientras que una configuración casi exclusivamente explotatoria ($\tau = 0,1$) destaca en el caso de Bernoulli. La configuración altamente exploratoria obtiene muy malos resultados ($\tau = 10$) para todas las distribuciones. Para el experimento final, usaremos el gradiente de preferencias con $\alpha = 0,1$ (estándar) como mejor representante de los algoritmos basados en el gradiente.


4.4. Comparación final de los mejores algoritmos de cada familia.

En esta sección comparemos el algoritmo que ha obtenido los mejores resultados dentro de cada familia:


- ▶ ϵ -greedy con $\epsilon = 0,1$ (azul).
- ▶ UCB-2 con $\alpha = 0,1$ (naranja).
- ▶ Gradiente de preferencias con $\alpha = 0,1$ (verde).

4.4.1. Comparación entre los mejores algoritmos para distribución normal.


En la Figura 10, podemos observar como se comportan los mejores algoritmos de cada familia con una distribución normal de las recompensas de los brazos. Entre estos cabe destacar UCB-2, que consigue la convergencia más rápida en las curvas de recompensa acumulada, seguido del gradiente de preferencias y dejando en último lugar a ϵ -greedy. Lo mismo ocurre en la curva de selecciones óptimas, teniendo además una convergencia más rápida del regret acumulado que el resto de configuraciones. En definitiva, UCB-2 con $\alpha = 0,1$, es el algoritmo que mejor funciona dentro de los probados para resolver el bandido de k brazos cuyas recompensas siguen una distribución normal.



(a) Evolución de la recompensa acumulada



(b) Evolución del porcentaje de selecciones óptimas



(c) Evolución del rechazo acumulado

Figura 10: Resultados del estudio de los mejores algoritmos de cada familia para distribución normal.

4.4.2. Algoritmos basados en el gradiente para distribución de Bernoulli.


Observando las gráficas de la Figura 11, vemos que el algoritmo que más destaca es ϵ -greedy, convergiendo antes y consiguiendo superar al resto de familias tanto en la curva de porcentaje de aciertos como de regret acumulado. El algoritmo UCB-2 y gradiente de preferencias presentan resultados similares, salvando las típicas oscilaciones de UCB-2 al hacer varias exploraciones seguidas de un mismo brazo no-óptimo en su búsqueda del brazo con mejores recompensas.

4.4.3. Algoritmos basados en el gradiente para distribución binomial.


Las gráficas de la Figura 12 nos muestran que vuelven a darse curvas muy similares a las que ya hemos comentado para la distribución normal. Vuelve a predominar UCB-2, siendo el gradiente de preferencias el algoritmo con peores resultados y obteniendo resultados a medio camino con ϵ -greedy.

4.4.4. Análisis de la comparación de los mejores algoritmos.


En cuanto a los mejores modelos, el que consigue resultados más consistentes es UCB-2, que funciona muy bien y con



(a) Evolución de la recompensa acumulada



(b) Evolución del porcentaje de selecciones óptimas



(c) Evolución del rechazo acumulado


Figura 11: Resultados del estudio de los mejores algoritmos de cada familia para distribución de Bernoulli.

rápida convergencia para el caso de distribución normal y binomial. Como ya ha pasado en experimentos anteriores, para la distribución de Bernoulli obtenemos un resultado distinto, siendo el mejor algoritmo el ε -greedy. Estos resultados sugieren que no existe un único algoritmo estándar que funcione bien para todas las distribuciones de recompensa de los brazos, sino que la elección del algoritmo adecuado se hará en función de que distribución de recompensa se espera, resultando dicha elección fundamental para obtener la recompensa acumulada máxima.


5. Conclusiones

Las principales conclusiones que extraemos en la realización de los diversos experimentos son las siguientes:


- El algoritmo que mejores resultados arroja en una amplia variedad de situaciones es UCB-2 con una exploración estándar $\alpha = 0,1$. Otros algoritmos que destacan dentro de sus familias y que también presentan una convergencia buena serían ε -greedy con $\varepsilon = 0,1$ y el gradiente de preferencias con $\alpha = 0,1$.
- No existe un algoritmo perfecto que nos proporcione unos resultados muy buenos en todas las situaciones, es decir, en todas las diferentes distribuciones de probabilidad



(a) Evolución de la recompensa acumulada



(b) Evolución del porcentaje de selecciones óptimas



(c) Evolución del rechazo acumulado

Figura 12: Resultados del estudio de los mejores algoritmos de cada familia para distribución binomial.

de recompensa de los brazos. Algoritmos con resultados muy buenos para algunas distribuciones populares como la normal no funcionan bien en otras como la Bernoulli.

- Por lo general, las estrategias que pecan de demasiado explotatorias o exploratorias no consiguen buenos resultados. Cuando la tasa de explotación es muy alta resulta difícil llegar a determinar cuál es el brazo óptimo, lo que lleva a que el porcentaje de elecciones óptimas sea bajo al igual que la recompensa acumulada y a que el regret sea alto. En el caso de algoritmos muy exploratorios, aunque ya hayan encontrado la solución óptima siguen explorando brazos menos prometedores lo que lleva a que las selecciones óptimas disminuyan.

Referencias

- [1] T. L. Lai and H. Robbins, "Asymptotically efficient adaptive allocation rules," *Advances in Applied Mathematics*, vol. 6, no. 1, pp. 4–22, 1985.
- [2] D. Bouneffouf, I. Rish, and C. Aggarwal, "Survey on applications of multi-armed and contextual bandits," *IEEE Congress on Evolutionary Computation (CEC)*, pp. 1–8, 2020.
- [3] P. Auer, N. Cesa-Bianchi, and P. Fischer, "Finite-time

- analysis of the multiarmed bandit problem,” *Machine Learning*, vol. 47, no. 2-3, pp. 235–256, 2002.
- [4] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*. MIT Press, 2nd ed., 2018.
- [5] L. D. Hernández, “Código base bandido k-brazos.” https://colab.research.google.com/github/ldaniel-hm/eml_k_bandit/blob/main/bandit_experiment.ipynb, 2023. Accessed: March 2025.